

Re(正则表达式)库入门

WS07



嵩天

www.python123.org

The Website is the API ...



Requests

自动爬取HTML页面
自动网络请求提交

robots.txt

网络爬虫排除标准



Beautiful Soup

解析HTML页面



Re

正则表达式详解
提取页面关键信息



掌握定向网络数据爬取和网页解析的基本能力

Python网络爬虫与信息提取

python
弹指之间 · 享受创新

04X -Tian



正则表达式的概念

正则表达式

regular expression, regex, RE

正则表达式是用来简洁表达一组字符串的表达式

'PN'

'PYN'

'PYTN'

'PYTHN'

'PYTHON'



正则表达式：

$P(Y|YT|YTH|YTHO)?N$

一组字符串

简洁表达

正则表达式

regular expression, regex, RE

使用正则表达式的优势是什么？

简洁

一行胜千言

一行就是特征(模式)

正则表达式

regular expression, regex, RE

'PY'

'PYY'

'PYYY'

'PYYYY'

.....

'PYYYYY.....'



正则表达式：

PY+

一组字符串（无穷个）

无穷字符串组的简洁表达

正则表达式

regular expression, regex, RE

'PY' 开头

后续存在不多于10个字符

后续字符不能是 'P' 或 'Y'

'PYABC' ✓

'PYKXYZ' ✗



正则表达式：

`PY[^PY]{0,10}`

一组具有某些特点的字符串
(可以枚举，但很繁琐)

某种特征字符串组的简洁表达

正则表达式

regular expression, regex, RE

正则表达式是用来简洁表达一组字符串的表达式

正则表达式是一种通用的字符串表达框架

进一步

正则表达式是一种针对字符串表达“简洁”和“特征”思想的工具

正则表达式可以用来判断某字符串的特征归属

正则表达式

regular expression, regex, RE

正则表达式在文本处理中十分常用：

表达文本类型的特征（病毒、入侵等）

同时查找或替换一组字符串

匹配字符串的全部或部分 最主要应用在字符串匹配中

.....

正则表达式的使用

'PN'

'PYN'

'PYTN'

'PYTHN'

'PYTHON'



正则表达式：

$P(Y|YT|YTH|YTHO)?N$

`regex='P(Y|YT|YTH|YTHO)?N'`

编译



`p=re.compile(regex)`

特征 (p)

编译：将符合正则表达式语法的字符串转换成正则表达式特征



正则表达式的语法

正则表达式的语法


P(Y|YT|YTH|YTHO)?N

正则表达式语法由字符和操作符构成

正则表达式的常用操作符(1)



操作符	说明	实例
.	表示任何单个字符	
[]	字符集，对单个字符给出取值范围	[abc]表示a、b、c，[a-z]表示a到z单个字符
[^]	非字符集，对单个字符给出排除范围	[^abc]表示非a或b或c的单个字符
*	前一个字符0次或无限次扩展	abc* 表示 ab、abc、abcc、abccc等
+	前一个字符1次或无限次扩展	abc+ 表示 abc、abcc、abccc等
?	前一个字符0次或1次扩展	abc? 表示 ab、abc
	左右表达式任意一个	abc def 表示 abc、def



正则表达式的常用操作符(2)

操作符	说明	实例
{m}	扩展前一个字符m次	ab{2}c表示abbc
{m,n}	扩展前一个字符m至n次 (含n)	ab{1,2}c表示abc、 abbc
^	匹配字符串开头	^abc表示abc且在一个字符串的开头
\$	匹配字符串结尾	abc\$表示abc且在一个字符串的结尾
()	分组标记，内部只能使用 操作符	(abc)表示abc，(abc def)表示abc、 def
\d	数字，等价于[0-9]	
\w	单词字符，等价于[A-Za-z0-9_]	

正则表达式语法实例

<code>P(Y YT YTH YTHO)?N</code>	<code>'PN'、'PYN'、'PYTN'、'PYTHN'、'PYTHON'</code>
<code>PYTHON+</code>	<code>'PYTHON'、'PYTHONN'、'PYTHONNN' ...</code>
<code>PY[TH]ON</code>	<code>'PYTON'、'PYHON'</code>
<code>PY[^TH]?ON</code>	<code>'PYON'、'PYaON'、'PYbON'、'PYcON'...</code>
<code>PY{:3}N</code>	<code>'PN'、'PYN'、'PYYN'、'PYYYN'...</code>

正则表达式

对应字符串

经典正则表达式实例

`^[A-Za-z]+$`

由26个字母组成的字符串

`^[A-Za-z0-9]+$`

由26个字母和数字组成的字符串

`^-?\d+$`

整数形式的字符串

`^[0-9]*[1-9][0-9]*$`

正整数形式的字符串

`[1-9]\d{5}`

中国境内邮政编码，6位

`[\u4e00-\u9fa5]`

匹配中文字符

`\d{3}-\d{8}|\d{4}-\d{7}`

国内电话号码，010-68913536

匹配IP地址的正则表达式

IP地址字符串形式的正则表达式 (IP地址分4段, 每段0-255)

`\d+.\d+.\d+.\d+` 或 `\d{1,3}.\d{1,3}.\d{1,3}.\d{1,3}`

精确写法

0-99 : `[1-9]?\d`

100-199: `1\d{2}`

200-249: `2[0-4]\d`

250-255: `25[0-5]`

`(([1-9]?\d|1\d{2}|2[0-4]\d|25[0-5])).{3}([1-9]?\d|1\d{2}|2[0-4]\d|25[0-5])`



Re库的基本使用

Re库介绍

Re库是Python的标准库，主要用于字符串匹配

调用方式：

```
import re
```

正则表达式的表示类型

raw string类型（原生字符串类型）

re库采用raw string类型表示正则表达式，表示为：

`r'text'`

例如：`r'[1-9]\d{5}'`

`r'\d{3}-\d{8}|\d{4}-\d{7}'`

raw string是不包含对转义符再次转义的字符串

正则表达式的表示类型

re库也可以采用string类型表示正则表达式，但更繁琐

例如：

```
'[1-9]\\d{5}'
```

```
'\\d{3}-\\d{8}|\\d{4}-\\d{7}'
```

建议：当正则表达式包含转义符时，使用raw string

Re库主要功能函数

函数	说明
<code>re.search()</code>	在一个字符串中搜索匹配正则表达式的第一个位置，返回match对象
<code>re.match()</code>	从一个字符串的开始位置起匹配正则表达式，返回match对象
<code>re.findall()</code>	搜索字符串，以列表类型返回全部能匹配的子串
<code>re.split()</code>	将一个字符串按照正则表达式匹配结果进行分割，返回列表类型
<code>re.finditer()</code>	搜索字符串，返回一个匹配结果的迭代类型，每个迭代元素是match对象
<code>re.sub()</code>	在一个字符串中替换所有匹配正则表达式的子串，返回替换后的字符串

```
re.search(pattern, string, flags=0)
```

在一个字符串中搜索匹配正则表达式的第一个位置
返回match对象

- **pattern** : 正则表达式的字符串或原生字符串表示
- **string** : 待匹配字符串
- **flags** : 正则表达式使用时的控制标记

`re.search(pattern, string, flags=0)`

- **flags** : 正则表达式使用时的控制标记

常用标记	说明
re.I re.IGNORECASE	忽略正则表达式的大小写，[A-Z]能够匹配小写字符
re.M re.MULTILINE	正则表达式中的^操作符能够将给定字符串的每行当作匹配开始
re.S re.DOTALL	正则表达式中的.操作符能够匹配所有字符，默认匹配除换行外的所有字符

`re.search(pattern, string, flags=0)`

```
>>> import re
>>> match = re.search(r'[1-9]\d{5}', 'BIT 100081')
>>> if match:
    print(match.group(0))
```

100081

```
>>>
```

```
re.match(pattern, string, flags=0)
```

从一个字符串的开始位置起匹配正则表达式
返回match对象

- **pattern** : 正则表达式的字符串或原生字符串表示
- **string** : 待匹配字符串
- **flags** : 正则表达式使用时的控制标记

re.match(pattern, string, flags=0)

```
>>> import re
>>> match = re.match(r'[1-9]\d{5}', 'BIT 100081')
>>> if match:
    match.group(0)

>>> match.group(0)
Traceback (most recent call last):
  File "<pyshell#14>", line 1, in <module>
    match.group(0)
AttributeError: 'NoneType' object has no attribute 'group'
>>> match = re.match(r'[1-9]\d{5}', '100081 BIT')
>>> if match:
    match.group(0)

'100081'
>>>
```

```
re.findall(pattern, string, flags=0)
```

搜索字符串，以列表类型返回全部能匹配的子串

- **pattern** : 正则表达式的字符串或原生字符串表示
- **string** : 待匹配字符串
- **flags** : 正则表达式使用时的控制标记

`re.findall(pattern, string, flags=0)`

```
>>> import re
>>> ls = re.findall(r'[1-9]\d{5}', 'BIT100081 TSU100084')
>>> ls
['100081', '100084']
>>>
```

使用 `re.compile() + pattern.findall(string[, pos[, endpos[)])`
和直接使用 `re.findall()` 函数不一样

```
import re
pattern = re.compile(r'\d+') # 查找数字
result = pattern.findall('run88oob123google456', 0, 10)
print(result)
```

```
re.split(pattern, string, maxsplit=0, flags=0)
```

将一个字符串按照正则表达式匹配结果进行分割
返回列表类型

- **pattern** : 正则表达式的字符串或原生字符串表示
- **string** : 待匹配字符串
- **maxsplit**: 最大分割数，剩余部分作为最后一个元素输出
- **flags** : 正则表达式使用时的控制标记

`re.split(pattern, string, maxsplit=0, flags=0)`

```
>>> import re
>>> re.split(r'[1-9]\d{5}', 'BIT100081 TSU100084')
['BIT', ' TSU', '']
>>> re.split(r'[1-9]\d{5}', 'BIT100081 TSU100084', maxsplit=1)
['BIT', ' TSU100084']
>>>
```

```
re.finditer(pattern, string, flags=0)
```

搜索字符串，返回一个匹配结果的迭代类型，每个迭代元素是match对象

- **pattern** : 正则表达式的字符串或原生字符串表示
- **string** : 待匹配字符串
- **flags** : 正则表达式使用时的控制标记

`re.finditer(pattern, string, flags=0)`

```
>>> import re
>>> for m in re.finditer(r'[1-9]\d{5}', 'BIT100081 TSU100084'):
    if m:
        print(m.group(0))
```

```
100081
100084
>>>
```

finditer 找到正则表达式所匹配的所有子串，并把它们作为一个迭代器返回

每个迭代元素是match对象，不是每个迭代器！！！！所以此处要用非循环把每个元素遍历一遍才能用match的group()方法

```
re.sub(pattern, repl, string, count=0, flags=0)
```

在一个字符串中替换所有匹配正则表达式的子串
返回替换后的字符串

- **pattern** : 正则表达式的字符串或原生字符串表示
- **repl** : 替换匹配字符串的字符串
- **string** : 待匹配字符串
- **count** : 匹配的最大替换次数
- **flags** : 正则表达式使用时的控制标记

`re.sub(pattern, repl, string, count=0, flags=0)`

```
>>> import re
>>> re.sub(r'[1-9]\d{5}', ':zipcode', 'BIT100081 TSU100084')
'BIT:zipcode TSU:zipcode'
>>>
```

Re库主要功能函数

函数	说明
<code>re.search()</code>	在一个字符串中搜索匹配正则表达式的第一个位置，返回match对象
<code>re.match()</code>	从一个字符串的开始位置起匹配正则表达式，返回match对象
<code>re.findall()</code>	搜索字符串，以列表类型返回全部能匹配的子串
<code>re.split()</code>	将一个字符串按照正则表达式匹配结果进行分割，返回列表类型
<code>re.finditer()</code>	搜索字符串，返回一个匹配结果的迭代类型，每个迭代元素是match对象
<code>re.sub()</code>	在一个字符串中替换所有匹配正则表达式的子串，返回替换后的字符串

for 循环访问每个元素

Re库的另一种等价用法

```
>>> rst = re.search(r'[1-9]\d{5}', 'BIT 100081')
```

函数式用法：一次性操作



```
>>> pat = re.compile(r'[1-9]\d{5}')  
>>> rst = pat.search('BIT 100081')
```

面向对象用法：编译后的多次操作

```
regex = re.compile(pattern, flags=0)
```


将正则表达式的字符串形式编译成正则表达式对象

- **pattern** : 正则表达式的字符串或原生字符串表示
- **flags** : 正则表达式使用时的控制标记

```
>>> regex = re.compile(r'[1-9]\d{5}')
```

Re库的另一种等价用法

函数	说明
<code>regex.search()</code>	在一个字符串中搜索匹配正则表达式的第一个位置，返回match对象
<code>regex.match()</code>	从一个字符串的开始位置起匹配正则表达式，返回match对象
<code>regex.findall()</code>	搜索字符串，以列表类型返回全部能匹配的子串
<code>regex.split()</code>	将一个字符串按照正则表达式匹配结果进行分割，返回列表类型
<code>regex.finditer()</code>	搜索字符串，返回一个匹配结果的迭代类型，每个迭代元素是match对象
<code>regex.sub()</code>	在一个字符串中替换所有匹配正则表达式的子串，返回替换后的字符串



Match对象介绍

Match对象是一次匹配的结果，包含匹配的很多信息

```
>>> match = re.search(r'[1-9]\d{5}', 'BIT 100081')
>>> if match:
    print(match.group(0))
>>> type(match)
<class '_sre.SRE_Match'>
```

Match对象的属性

属性	说明
<code>.string</code>	待匹配的文本
<code>.re</code>	匹配时使用的patter对象（正则表达式）
<code>.pos</code>	正则表达式搜索文本的开始位置
<code>.endpos</code>	正则表达式搜索文本的结束位置

Match对象的方法

方法	说明
<code>.group(0)</code>	获得匹配后的字符串
<code>.start()</code>	匹配字符串在原始字符串的开始位置
<code>.end()</code>	匹配字符串在原始字符串的结束位置
<code>.span()</code>	返回(<code>.start()</code> , <code>.end()</code>)

Match对象实例

```
>>> import re
>>> m = re.search(r'[1-9]\d{5}', "BIT100081 TSU100084")
>>> m.string
'BIT100081 TSU100084'
>>> m.re
re.compile('[1-9]\\d{5}')
>>> m.pos
0
>>> m.endpos
19
>>> m.group(0)
'100081'
>>> m.start()
3
>>> m.end()
9
>>> m.span()
(3, 9)
```



Re库的贪婪匹配和最小匹配

实例

```
>>> match = re.search(r'PY.*N', 'PYANBNCNDN')  
>>> match.group(0)
```

同时匹配长短不同的多项，返回哪一个呢？

贪婪匹配

```
>>> match = re.search(r'PY.*N', 'PYANBNCNDN')
>>> match.group(0)
'PYANBNCNDN'
```

Re库默认采用贪婪匹配，即输出匹配最长的子串

最小匹配

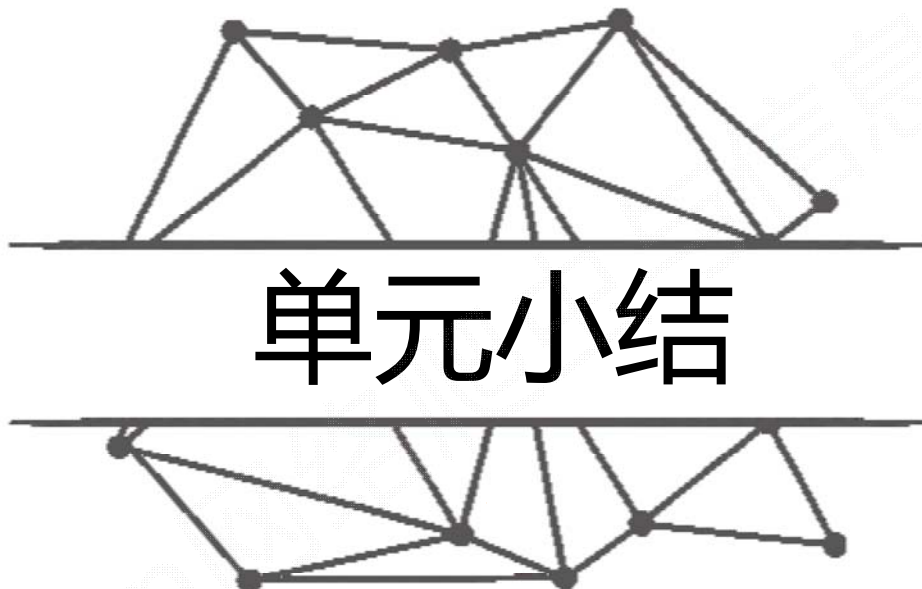
如何输出最短的子串呢？

```
>>> match = re.search(r'PY.*?N', 'PYANBNCNDN')
>>> match.group(0)
'PYAN'
```


最小匹配操作符

操作符	说明
*?	前一个字符0次或无限次扩展，最小匹配
+?	前一个字符1次或无限次扩展，最小匹配
??	前一个字符0次或1次扩展，最小匹配
{m,n}?	扩展前一个字符m至n次（含n），最小匹配

只要长度输出可能不同的，都可以通过在操作符后增加?变成最小匹配



单元小结

Re库(正则表达式)入门

正则表达式是用来简洁表达一组字符串的表达式

```
r'\d{3}-\d{8}|\d{4}-\d{7}'
```

`re.search()`

`re.match()`

`re.findall()`

`re.split()`

`re.finditer()`

`re.sub()`

`=`

`regex=re.compile()`

`+`

`regex.search()`

`regex.match()`

`regex.findall()`

`regex.split()`

`regex.finditer()`

`regex.sub()`